

Диффузионные модели. Персонализированная генерация изображений на основе текста: Textual Inversion, DreamBooth и Custom Diffusion

Шкулева Ксения
ksshkuleva@gmail.com

18 апреля 2025 г.

Оглавление

1	Введение	2
1.1	Общий контекст	2
1.2	Постановка задачи	2
1.3	Цели и задачи	2
2	Обзор литературы	3
2.1	Diffusion Model	3
2.2	Stable Diffusion Model	4
2.3	Textual Inversion	4
2.4	DreamBooth	5
2.5	Custom Diffusion	5
3	Воспроизведение основных бейзлайнов	6
3.1	Наборы данных	6
3.2	Метрики	6
3.3	Список базовых методов	7
3.4	Результаты и обсуждение	7
3.5	Конфигурация и параметры	8
3.6	Анализ ограничений базовых методов	8
4	Заключение	9
5	Ссылки	9

Оглавление

1 Введение

1.1 Общий контекст

Генерация изображений на основе текстовых описаний — это активно развивающаяся область искусственного интеллекта, которая позволяет создавать изображения по текстовым запросам. Такие методы как Textual Inversion, DreamBooth и Custom Diffusion показали значительные успехи в этой области. Эти методы позволяют персонализировать генерацию изображений, обучая модели на небольших наборах данных. Все эти методы были разработаны и оптимизированы для классической архитектуры Stable Diffusion, которая использует UNet в качестве основного блока. В то же время, современные подходы к диффузионным моделям, такие как DiT (Diffusion Transformer), переходят на полностью трансформерные архитектуры, что открывает новые возможности для улучшения качества и эффективности генерации.

1.2 Постановка задачи

Основная проблема заключается в том, что существующие методы персонализации генерации изображений были разработаны и протестированы на UNet-based диффузионных моделях, таких как Stable Diffusion. Однако современные подходы, такие как DiT, используют трансформерные архитектуры, которые могут предложить улучшенное качество и эффективность. Необходимо исследовать, как эти методы будут работать на новых трансформерных диффузионных моделях, и сравнить их производительность с классическими подходами. Это особенно актуально, так как UNet-based подходы постепенно устаревают, а новые модели, такие как DiT, становятся стандартом в области генерации изображений.

1.3 Цели и задачи

- Изучить релевантные работы по диффузионным моделям и методам персонализации генерации изображений.
- Воспроизвести базовые методы (Textual Inversion, DreamBooth, Custom Diffusion) на классической архитектуре Stable Diffusion.
- Реализовать и адаптировать эти методы для работы с трансформерной диффузионной моделью DiT.
- Провести сравнительный анализ методов по метрикам качества, памяти и скорости на обеих архитектурах.

- Сравнить результаты работы методов на DiT с их производительностью на Stable Diffusion.

2 Обзор литературы

В этом разделе представлен обзор существующих методов генерации изображений на основе текста, включая Textual Inversion, DreamBooth и Custom Diffusion.

2.1 Diffusion Model

Диффузионные модели основаны на идее постепенного добавления шума к данным (прямой процесс) и последующего восстановления данных из шума (обратный процесс). Прямой процесс моделируется как марковский процесс, где на каждом шаге данные зашумляются по формуле:

$$x_t = \sqrt{1 - \beta_t}x_{t-1} + \sqrt{\beta_t}\epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I)$$

Обратный процесс учится восстанавливать данные из шума, используя нейронную сеть для предсказания шума на каждом шаге.

Диффузионные модели демонстрируют высокое качество генерации изображений, особенно в задачах, где требуется детализация и реалистичность. Примеры можно посмотреть на рисунке 1.




Рис. 1: Примеры полученные Diffusion Model

Преимущества этой модели перед GAN

- Диффузионные модели более стабильные, так как шум добавляется постепенно.
- Диффузионные модели часто превосходят GAN по качеству и детализации сгенерированных изображений.

2.2 Stable Diffusion Model

Stable Diffusion — современная диффузионная модель, работающая в латентном пространстве для снижения вычислительных затрат. Её ключевые компоненты:

- Изображения сжимаются в компактное представление через автоэнкодер:

$$z = \text{Encoder}(x), \quad x_{\text{rec}} = \text{Decoder}(z)$$

- Текст кодируется моделью CLIP:

$$c = \text{CLIP}(y)$$

где y — текстовый промпт, c — его векторное представление. Этот вектор c используется для conditioning(условной генерации) в процессе обратной диффузии.

- Обратная диффузия, шум удаляется из латентного представления с учётом текстового условия:

$$z_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(z_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(z_t, t, c) \right) + \sigma_t \eta$$

Здесь ϵ_{θ} — нейронная сеть, которая предсказывает шум на каждом шаге, используя текстовый контекст c .

Преимущества:

- Эффективность за счёт работы в латентном пространстве.
- Высокое качество генерации (детализация, реалистичность).
- Картинки генерируются в зависимости от текстовых условий.

2.3 Textual Inversion

Метод: на вход поступает несколько картинок и в текстовом кодировщике выделяется специальный токен (например, S^*), чей вектор эмбединга обучается. Текстовый кодировщик преобразует S^* в оптимизируемый вектор. Модель оптимизирует этот вектор так, чтобы запросы вида “Фото $[S]^*$ ” воспроизводили изображения из входного набора. Используется LDM-потеря (латентная диффузионная модель), которая измеряет расхождение между сгенерированными и реальными изображениями. Параметры генеративной модели заморожены — обучается только вектор S^* . Обучение проводится через градиентный спуск, где обновляется только вектор S^* , а не веса всей модели. Диффузионная модель использует этот вектор как часть текстового условия для генерации изображений.

На рисунке 2 можно посмотреть как работает модель Textual Inversion, мы представили модели несколько фотографий одинакового стиля и модель научилась генерировать похожего стиля фотографии.




Рис. 2: Примеры полученные Textual Inversion

2.4 DreamBooth

Как работает метод : даем 3-5 изображений одного объекта на фотографиях. Объект предоставленный на изображениях ассоциируется с редким токеном, который не имеет сильной семантической нагрузки в исходной модели. Это позволяет избежать конфликтов с существующими понятиями. Модель дообучается на предоставленных изображениях объекта. Текстовые подсказки для обучения включают уникальный идентификатор и класс объекта. Обучение проходит с сохранением исходных параметров модели, чтобы не нарушить её общие способности к генерации, оценка loss устроена так чтобы учитывать баланс сохранения прошлых знаний и новых знаний после полученного объекта.




Рис. 3: Примеры полученные DreamBooth

На рисунке 3 можно посмотреть как работает модель DreamBooth, мы представили модели несколько фотографий одинакового объекта и модель научилась генерировать этот объект в разных стилях/концепциях.

2.5 Custom Diffusion

Метод Custom Diffusion работает за счёт тонкой настройки диффузионных моделей для обучения новым концепциям на основе нескольких примеров. Вместо обновления всех параметров модели метод фокусируется на оптимизации ключевых (key) и value-матриц в слоях кросс-внимания, которые отвечают за взаимодействие текстовых и визуальных признаков в СА-блоках (Cross-Attention). Помимо матриц, метод также обучает уникальные текстовые эмбединги для каждой новой концепции — аналогично подходу Textual Inversion. В совокупности эти параметры составляют




Рис. 4: Примеры полученные Custom Diffusion

всего 5% от общего числа весов модели, что значительно снижает вычислительные затраты.

Для предотвращения переобучения на малых данных используется регуляризация на основе реальных изображений со схожими текстовыми описаниями. Это помогает модели сохранять ранее усвоенные общие знания и избегать «забывания»

Метод поддерживает одновременное обучение нескольким концепциям. Для каждой из них вводится уникальный модификатор токена, который инициализируется редким словом из словаря и оптимизируется совместно с key- и value-матрицами. Если модели уже обучены на разных концепциях по отдельности, их можно объединить в единую систему через оптимизацию с ограничениями, используя метод Лагранжа, минимизируя конфликты между концепциями.

На рисунке 4 можно посмотреть как работает модель Custom Diffusion, мы научили ее генерировать moongate и конкретную собаку. И эта модель умеет объединять эти 2 концепции на фотографиях.

3 Воспроизведение основных бейзлайнов

3.1 Наборы данных

Textual Inversion, DreamBooth, Custom Diffusion обучались на малых пользовательских наборах, но базировались на предобученной модели Stable Diffusion (LAION-5B).

Stable Diffusion обучалась на LAION-5B — публичном датасете из 5 млрд пар "текст-изображение".

COCO и Flickr30k — стандартные бенчмарки для оценки генеративных моделей.

Все 3 модели сравнивались на одном eval-сете в статье про Custom Diffusion.

3.2 Метрики

Для оценки методов используются следующие метрики:

- Метрика Text-alignment(CLIP-T) вычисляется как косинусное сходство между

текстовым описанием и сгенерированным изображением:

$$\text{Text-alignment (CLIP-T)} = \cos(\theta) = \frac{\mathbf{c} \cdot \mathbf{v}}{\|\mathbf{c}\| \|\mathbf{v}\|}$$

где $\mathbf{c}$ — CLIP-эмбединг текста, $\mathbf{v}$ — CLIP-эмбединг изображения.

- Метрика Image-alignment (CLIP-I) показывает соответствие сгенерированного изображения целевому концепту, вычисляется как косинусное расстояние между CLIP-эмбедингами сгенерированного и референсного изображений:

$$\text{Image-alignment (CLIP-I)} = \cos(\theta) = \frac{\mathbf{v}_{\text{gen}} \cdot \mathbf{v}_{\text{ref}}}{\|\mathbf{v}_{\text{gen}}\| \|\mathbf{v}_{\text{ref}}\|}$$

- Метрика KID измеряет схожесть распределений реальных и сгенерированных изображений:

$$\text{KID} = \frac{1}{n(n-1)} \sum_{i \neq j} k(\mathbf{x}_i, \mathbf{x}_j) + \frac{1}{m(m-1)} \sum_{i \neq j} k(\mathbf{y}_i, \mathbf{y}_j) - \frac{2}{nm} \sum_{i,j} k(\mathbf{x}_i, \mathbf{y}_j)$$

3.3 Список базовых методов

- Textual Inversion - метод, который обучает специальный токен для воспроизведения специфических стилей или объектов.
- DreamBooth - метод, который дообучает модель на нескольких изображениях объекта, ассоциируя его с редким токеном.
- Custom Diffusion - метод, который оптимизирует ключевые и value-матрицы в слоях кросс-внимания для обучения новым концепциям.

3.4 Результаты и обсуждение

	Method	Text-alignment	Image-alignment	KID (validation)
Single-Concept	Textual Inversion	0.670	0.827	22.27
	DreamBooth	0.781	0.776	32.53
	Ours (w/ fine-tune all)	0.795	0.748	19.27
	Ours	0.795	0.775	20.96
Multi-Concept	Textual Inversion	0.544	0.630	—
	DreamBooth	0.783	0.695	
	Ours (w/ fine-tune all)	0.787	0.691	
	Ours (Sequential)	0.797	0.700	
	Ours (Optimization)	0.800	0.695	
	Ours (Joint)	0.801	0.706	

Рис. 5: Сравнение Textual Inversion, DreamBooth Custom Diffusion

Посмотрим на рисунок 5 и сделаем вывод зная что значит каждая метрика, где ours - Custom Diffusion model, single-concept - сравнение моделей в одной концепции, а multi-concept - сравнение моделей с несколькими концепциями.

- Textual Inversion нужен для добавления уникальнй объект или стиль с минимальными данными, а соответствие тексту не критично.

- DreamBooth нужен для точного следования текстовым инструкциям, но можно пожертвовать качеством изображения.
- Custom Diffusion нужен для сложных задач с несколькими концептами, где важен баланс между текстом, изображением и качеством.

3.5 Конфигурация и параметры

Метод	Время обучения	Память для обучения	Память для хранения модели
DreamBooth	~1 час	~3 ГБ	~3 ГБ
Textual Inversion	~20 минут	~75 МБ	~75 МБ
Custom Diffusion	~6 минут	~75 МБ	~75 МБ

Рис. 6: Сравнение Textual Inversion, DreamBooth, Custom Diffusion по памяти и скорости

Textual Inversion — легкий метод с точки зрения ресурсов, но он менее гибок и не поддерживает мульти-концепты.

DreamBooth — мощный метод, но требует значительных ресурсов для обучения и хранения модели. Он подходит для задач, где важна высокая точность и гибкость.

Custom Diffusion — оптимальный метод, который сочетает в себе скорость, низкие требования к памяти и поддержку мульти-концептов. Он подходит для задач, где важна эффективность и возможность работы с несколькими концептами.

3.6 Анализ ограничений базовых методов

- Textual Inversion: хорошо справляется с передачей стиля, но менее гибок в работе с несколькими концептами.
- DreamBooth: требует значительных ресурсов для обучения, но обеспечивает высокую точность.
- Custom Diffusion: оптимальный метод для задач с несколькими концептами, но требует доработки для улучшения качества изображений.

4 Заключение

Диффузионные модели часто превосходят GAN по качеству и детализации сгенерированных изображений.

DreamBooth показывает самую высокую точность, но требует больших ресурсов

У Textual Inversion и DreamBooth обучение проходит относительно быстро, так как обновляется только часть модели, а не все параметры модели.

Методы позволяют комбинировать несколько выученных концептов, что делает их гибкими для различных задач.

5 ССЫЛКИ

- [Textual Inversion источник](#)
- [DreamBooth источник](#)
- [Custom Diffusion источник](#)
- [Презентация на диффузионные модели](#)
- [Мой разбор статьи Textual Inversion](#)
- [Мой разбор статьи DreamBooth](#)
- [Мой разбор статьи Custom Diffusion](#)